

דו"ח ניתוח עסקי לשוק ה-Airbnb בניו יורק לשנת 2019

מאת: יואב ויתקון

מטרת המחקר: ניתוח השוק וזיהוי סגמנטים עיקריים בשוק, ניתוח הגורמים העיקריים המשפיעים על המחיר בשוק, ויצירת תובנות שיאפשרו חיזוי מחירי נכסים.

מטרה עסקית: לאפשר לבעלי נכסים בעיר ניו יורק דרך לקבוע את מחיר הדירה ללילה בפלטפורמת ה-Airbnb.

מבנה מערך הנתונים: הנתונים שלנו מורכבים מ-16 עמודות ו-48,858 שורות. כל שורה מייצגת נכס בעיר.

id מזהה ייחודי לכל נכס.

name שם הנכס כפי שמופיע באתר.

host_id מזהה של המארח.

host_name שם המארח.

neighbourhood_group האזור הגיאוגרפי הכללי בעיר.

neighbourhood השכונה המדויקת שבה נמצא הנכס.

latitude קואורדינטת קו רוחב של מיקום הנכס.

longitude קואורדינטת קו אורך של מיקום הנכס.

room_type סוג הנכס.

price מחיר ללילה ← **עמודת המטרה שלנו.**

minimum_nights מינימום לילות להזמנה.

number_of_reviews מספר הביקורות שהנכס קיבל.

last_review תאריך הביקורת האחרונה.

reviews_per_month ממוצע ביקורות לחודש.

calculated_host_listings_count מספר הנכסים של אותו מארח.

availability_365 מספר הימים בשנה שבהם הנכס זמין להזמנה.

שלב א' - הבנת הנתונים

בשלב הראשון חיפשנו ומצאנו כי קיימים מספר ערכים חסרים. בעמודות: "name","host_name" מספר הערכים החסרים בהן 21, 16 בהתאמה. זהו מספר זניח של שורות מתוך מערך הנתונים הכללי שלנו. לכן, החלטנו להשמיט אותם. בעמודות "reviews_per_month", "last_review" נמצאו 10,052 שורות בעלי ערכים חסרים ולכן השלמנו את הערכים החסרים ל "0".

סינון ערכים חריגים-

זיהינו כי קיימות מספר דירות בהן המחיר לילה הינו 0 דולרים ודירות שהזמינות שלהן היא 0 ימים בשנה. החלטנו לסנן את אותן הדירות מכיוון שהן לא משקפות את המצב בשוק ולא רלוונטיות לשוק העדכני אותו אנחנו חוקרים. לאחר סינון נשארו במערך הנתונים שלנו 31,342 שורות.

סטטיסטיקות וניתוח ראשוני-

בעמודת ה-price נראתה סטיית תקן חריגה. במבט ראשוני נראה כי המחירים מפוזרים לאורך טווח רחב. במהלך בדיקה מעמיקה נמצא כי 95% מהנכסים בשוק בעלי עלות נמוכה מ\$400 ללילה, וה-5% הנותרים הם בטווח שבין \$400-\$10,000 ללילה. הערכים הקיצוניים האלו יכולים להשפיע על הממוצע ולכן צריך להתחשב בהם.

מעמודת ה-minimum_nights למדנו כי קיימות דירות המיועדות לשהייה ארוכה ודירות המיועדות לשהייה קצרה. גם בעמודה זאת צריך להתחשב בערכים הקיצוניים (דירות שדורשות שהייה מינימלית של 1,250 לילות. לעומת הממוצע שהוא 7 לילות והחציון שהוא שלושה לילות).

מעמודת ה-availability_365 זיהינו כי לא כל הנכסים זמינים במשך כל השנה. קיימים נכסים שזמינים רק לתקופה קצובה במהלך השנה. בתחקור מעמיק נמצא כי: 26% מהדירות זמינות ליותר מעשרה חודשים בשנה, 57% מהדירות זמינות לתקופה של בין חודש לעשרה חודשים בשנה ו-16% מהדירות זמינות לתקופה של חודש או פחות. אנו מסיקים מכך שכנראה חלק מהנכסים נמצאים בשימוש פרטי חלק מהזמן ולא זמינים להשכרה כל הזמן, אולי חלק מהנכסים אשר נמצאים בבעלות פרטית משומשים באופן פרטי במהלך החופשים וזמינים בשאר הזמן.

מעמודת ה-calculated_host_listings_count אנחנו לומדים כי לחלק מבעלי הנכסים מחזיקים בבעלותם יותר מנכס אחד. בהמשך הדו"ח נגע בעוד נקודות בהקשר הזה.

שלב ב' - EDA וניתוח מעמיק

בשלב זה נעבור לפי כל עמודה וננסה לנתח את הנתונים שלה לעומק.


הרובעים אליהם שמופיעים במערך הנתונים שלנו הם (Brooklyn, Manhattan, Queens Staten Island, Bronx). 82% מהנכסים במערך הנתונים שלנו נמצאים במנהטן ובברוקלין. 20% הנותרים מתחלקים בין שלושת הרובעים האחרים.

מסקנה: ברוקלין ומנהטן הם נתח השוק העיקרי של הדירות ה-Airbnb בניו יורק נכון לשנת 2019.


בניתוח המחיר הממוצע ללילה לפי רובעים נמצא כי מנהטן מובילה עם ממוצע של כ-\$214 ללילה אחריה ברוקלין עם מוצע של \$133 ללילה, סטייט איילנד נמדדת ב-\$114 ללילה קווינס עם כ-\$100 ללילה והברונקס עם כ-\$89 ללילה. בהתאם למה שציין קודם, גודל הרובעים משפיע מאוד על הממוצע ולכן ברובעים קטנים הממוצע רגיש מאוד לערכים חריגים והוא לא משקף את התמונה המלאה, כדי לקבל אותה נסתכל בהמשך על מדדים סטטיסטיים נוספים.

כאשר מסתכלים על השכונות התמונה ההתחלתית קצת מטעה, קשה לראות בברור איזה שכונות הן היקרות ביותר וזאת כי, קיימות שכונות קטנות בעלות נכס בודד או שניים אשר מתומחרות במחיר גבוהה ולא מייצגות את המחיר האמיתי באותו אזור. למשל נכס בודד בשכונה בשם Fort Wadsworth שנמצאת ברובע state island בעלות של 800 דולר ללילה שממזב אותה כשכונה היקרה ביותר מבחינת מחיר ממוצע ללילה.

כדי להימנע משכונות חריגות כאלה ולקבל תמונה אמיתית של המחירים סיננו את השכונות שהן יש פחות מעשרה נכסים. אומנם מדובר ב-27.5% מהשכונות אך מבחינת נכסים מדובר ב-0.9% מכלל הנכסים הרשומים בנתונים. ממצא זה מחזק מאוד את התחושה התחושה שלנו לגבי ריכוזיות הדירות בשוק. (רוב הדירות נמצאות בשכונות שממוקמות במנהטן וברוקלין) לאחר הסינון. התמונה שקיבלנו התבהרה 9 מתוך 10 השכונות בעלות המחיר הממוצע הגבוה ביותר ממוקמות במנהטן, היחידה שאינה היא עוד שכונה מstate island שנקראת Randall Manor ולאחר בדיקה מעמיקה נמצאה בשכונה נכס אחד בעלות של \$5000 ללילה, שמסתכלים על הממוצע ללא אותה הדירה מתקבל כי הממוצע פוחת ב-\$260. כאשר הסתכלנו על עשרת השכונות בעלי העלות הממוצעת ללילה הזולה ביותר התמונה שקיבלנו הייתה יותר יציבה. וכפי שציפנו רוב השכונות ברשימה היו שכונות מרובע הברונקס.



בדיקה נוספת שערכנו- היא ניסיון למצוא קשר בין הרובע לבין סוג הנכס. כפי שנראה בגרף הראשון, רוב הנכסים במנהטן הם מסוג דירה/ בית פרטי. לעומת מנהטן, בברוקלין כמעט יש שוויון בין מספר הדירות/ הבתים פרטיים לבין מספר החדרים הפרטיים. כפי שניתן לראות בגרף השני שמציג לנו את הקשר שבין סוג הנכס למחיר הממוצע של כל סוג נכס ניתן לראות בבירור שנכסים מסוג בית פרטי/דירה הם היקרים ביותר עם מחיר ממוצע של מעל \$200 ללילה. כאשר משלבים את שני הממצאים האלו ביחד ניתן להסיק באופן חד משמעי **מדוע מנהטן היא הרובע בעלת המחיר הממוצע הגבוה ביותר.**



בשלב הבא בניתוח שלנו ניסיון למצוא קשר בין מספר הלילות המינימלי לשהיה בנכס לבין השכונה שבה הן ממוקמים. ההשערה שלנו היא ששכונות שבהן מספר הלילות הוא בודד הן כנראה שכונות שממוקמות ליד תחנות הרכבת או שדה התעופה ונועדו לאכלס את אלו שבדרכים ושכונות בעלות מספר לילות מינימלי גבוהה יחסית אלו שכונות שנועדו לשהיה ארוכה.

בדקנו מי הם אותם בעלי נכסים אשר מחזקים הכי הרבה נכסים, מהממצאים שקיבלנו ראינו שחלקם אנשים פרטיים וחלקם חברות להחזקת נדל"ן. ולאחד בדיקה ראינו כי הרוב המוחלט של הנכסים שבעלי הנכסים הגדולים מחזיקים בבעלותם. ממוקמים במנהטן. בחירה עיסקית מוצלחת בהתחשב בכך שמנהטן הרובע בעל נתח ההכנסות הגדול ביותר בשוק.

בנוגע לקשר שבין מספר הביקורות לבין המחיר לא הצלחנו למצוא מגמה, ברורה כן שמנו לב לכך שכל הנכסים בעלי יותר מ-500 ביקורות הם נכסים בעלמחיר ממוצע זול מאוד ושלנכסים בעלי מכיר גבוהה יותר אין אותו מספר של ביקורות (ואפילו לא קרוב).

לא הצלחנו למצוא קשר ישיר בין הזמינות של הנכס לבין המחיר שלו.

שלב ג- Data Preparation

בשלב זה הכנו את הנתונים לפני שימוש בכלים של למידת מכונה. בתהליך יצירת עמודת חדשות יצרנו מספר עמודות חדשות ומתאמות לנתונים שלנו בהתאם להנחיות תוך כדי שמירה על חלוקה מאוזנת של הקבוצות. חילקנו את עמודות `number_of_reviews` לרמות פופולריות של הנכס כך שהנכס עם הכי הרבה ביקורות נמצא בקטגוריה של הכי פופולרי וכו... את עמודת `availability_365` המרנו לרמות של זמינות שלוש קבוצות שבכל אחת מהן רמות זמינות אחרת. את עמודת `minimum_nights` בחרנו להמיר גם לשלוש קבוצות שמתארות את בוג השהיה שלך האם זאת השהיה קצרה בינונית או ארוכה. בנוסף המרנו גם את עמודת `price` לקבוצות של מחירים, למרות שזאת עמודת המטרה שלנו רצינו להקל על המודל לחזות באיזו קבוצת מחירים הנכס ולא ערך ספציפי. לסיום המרנו גם את עמודת `last_review` והפקנו ממנה כמה שנים עברו מאז הביקורת האחרונה מכיין שהיו לנו ערכים חסרים באותה העמודה החלפנו אותם ב-15 כדי שהמודל ידע שהם רחוקים. כדי להימנע ממערך נתונים ענק בחרנו את העמודת הרלוונטיות לנירמול ולקידוד ורק לאחר מכן נירמלנו וקודדנו את הנתונים בהתאם לשיטות שנלמדו בקורס ולפני הפעלת המודל המערך הנתונים שלנו מנה- (25,31342)

שלב ד-הפקת תובנות המודלים

לאחר הרצת הפונקציה `def get_kmeans_accuracy(data, top_k)`: החלטנו לבחור ב- $K=5$ אומנם הוא לא הפיק לנו את מדד הסילואט הגבוה ביותר אך הוא נתן לנו קלאסטרים מאוזנים בגודל שמאפשרים לנו מעקב עיסקי אחרי כל קלאסטר. ממודל `kmeans` אנחנו מסקים כי קלאסטר 0 הן דירות ובטים פרטיים בברוקלין ומנהטן גם קצאת בקווינס שרובן בעלי מחיר בינוני גובה ובעלי זמינות בינונית עד גבוהה. קלאסטר 1 הוא קלאסטר שכמעט כולו חדריים פרטיים בברוקלין מנהטן וקווינס בעלי מחיר זול יחסית הזמינות והשהיה לא מובהקים. קלאסטר 2 מונה את רוב החדריים הפרטיים בשוק ובוא גם קצת חדריים משותפים שרובם מיועדים לשהיה קצרה ובינונית. מהמודל של `randomforest` הסקנו כי שלושת המאפיינים שעזרו למודל לחזות באופן הטוב ביותר הם קווי האורך והרוחב ועמודת הזמינות.

הצעה לשיפור עתידי של הניתוח


במהלך הניתוח נמצא כי בברוקלין, בהשוואה למנהטן, שיעור בעלי הנכסים המחזיקים במספר רב של נכסים נמוך באופן יחסי. כמו כן, נמצא כי ברוקלין ומנהטן הן האזורים היקרים ביותר להשכרה בניו יורק, אך בניגוד לברוקלין - במנהטן יש ריכוז גבוה יותר של בעלי נכסים מרובי נכסים. תופעה זו עשויה להעיד על הבדל מבני בשוק הדיור בין הרבעים, במיוחד מבחינת שליטה, בעלות ותחרות. לאור זאת, שיפור עתידי בניתוח עשוי לכלול שילוב נתונים חיצוניים על שוק הנדל"ן (כגון מדדי שכר דירה או עסקאות נדל"ן בפועל), לצד ניתוח מעמיק של הקשר בין בעלות מרובה על נכסים לבין רמות המחירים בפלטפורמה. פילוח זה לפי רבע וסוג חדר עשוי להניב תובנות מדויקות יותר באשר להשפעות המבנה הכלכלי של כל רבע על דפוסי השכרת Airbnb.

להלן הנתונים:

-מספר בעלי הנכסים בשלושת הרבעים

neighbourhood_group	
Manhattan	1169
Queens	70
Brooklyn	9

-מחיר ממוצע של נכסים בכל רבע



תהליך הלמידה הקבוצתי לאורך הפרויקט

בתהליך העבודה שלנו נפגשנו יחד כצוות, כאשר כל אחד מאיתנו עיין בערכות נתונים שונות מהאתרים שהוזכרו בפרויקט. לאחר השוואה ובחינה, בחרנו יחד את הדאטה שנראתה לנו המתאימה והמרתקת ביותר - הן מבחינת אפשרויות כתיבת הקוד והן מבחינת הסקת מסקנות. במהלך כתיבת הקוד נעזרנו בחומר מהשיעורים וההרצאות, בדוגמאות של פרויקטים מהאתר שממנו לקחנו את הדאטה, ובנוסף, השתמשנו בכלי בינה מלאכותית (AI) כדי להבין לעומק את הנתונים. בתחילה התמקדנו בהצגת הנתונים על ידי יצירת טבלאות סטטיסטיות וגרפים, ורק לאחר מכן עברנו להסקת מסקנות. השלב שהיווה עבורנו אתגר משמעותי היה שלב 6: הלמידה המונחית והבלתי-מונחית. אך, בעזרת חומרי הלימוד מהקורס והכוונה שקיבלנו במהלך הסמסטר הצלחנו להתמודד ולהבין אותו טוב יותר. העבודה המשותפת חיזקה את שיתוף הפעולה בינינו, אפשרה לנו לחשוב יחד, להעמיק בניתוח הנתונים ולחוות תהליך שמדמה עבודה מקצועית אמיתית.

